DSAI4204 / HOUSE PRICES / EDA交接

我的数据EDA做了什么
中文过程说明

供队友撰写最终项目报告使用

整理日期：2026-11-06。依据用户指定GitHub仓库的固定版本，不把后续特征工程和建模结果倒写成EDA已完成的工作。

仓库：Mintie365/DSAI4204_HousePrice_Prediction
路径：house-prices/House_Price_EDA.ipynb
固定提交：697b337fc3ad28449f07e4b3d661a0b51e6f8bb3

点击打开固定版本的原始Notebook（GitHub）

资料完整性与本说明的范围

已读取远程Notebook，并逐字节核对本地副本；该版本共35个单元，包含编号1-14的数据分析与总结章节（另有0号环境设置）。其10张汇总CSV和11张PNG原图也与GitHub固定版本逐字节一致。交接包保存这些证据和文件哈希。

分析方向	实际完成的内容
认识数据	正确读取NA/None，确认行列与字段类型；将79个变量分为7组。
数据质量与目标	缺失、唯一值、主导值比例、近常量；SalePrice与ln(SalePrice)的统计和分布。
字段与房价的关系	35个数值字段的Pearson/Spearman；44个类别字段的组统计与eta-squared。
字段相互关系	数值相关对、代表性类别Cramér's V；面积×质量与分箱趋势。
筛查与衔接	79列互信息、综合筛查表、train/test一致性与15条异常审查标记。

本Notebook是探索性分析，不包含最终预测模型训练，不直接导出筛选后的训练特征集，也没有自动删异常样本。它的价值是为后续缺失处理、特征工程与模型验证提供依据。

02 / 数据读取、类型与业务分组

源Notebook单元（从0计）：单元3-9

训练集1460行×81列，测试集1459行×80列；79个共同预测字段以外，训练集另有Id与SalePrice，测试集另有Id。检查了目标非缺失且为正、Id无重复、训练和测试字段集合一致。含Id的完整训练行重复数为0，但这不等于已经排除重复房屋或重复交易。

读取/类型决策	为什么这样做
keep_default_na=False；na_values=[NA,空串]	只将NA和空单元视为缺失标记；保留MasVnrType中的字符串None。训练中None为864条，不能全部当作数据错误。
MSSubClass转字符串类别	该字段是住宅类型代码，不把数字大小解释为连续数量。
Id与SalePrice排除出预测字段列表	Id用于对齐，SalePrice是分析目标；最终参与EDA排名的是79个字段。
35数值 + 44类别	这是MSSubClass按类别处理后的口径，不应照CSV默认dtype写成36数值、43类别。

7组业务字段：用于组织分析，不是自动筛选

分组	字段数	代表字段
土地与位置	14	Neighborhood、LotArea、MSZoning
建筑结构与外观	15	OverallQual、YearBuilt、ExterQual
地下室	9	TotalBsmtSF、BsmtQual、BsmtFinType1
室内与居住空间	19	GrLivArea、FullBath、KitchenQual
车库与停车	8	GarageCars、GarageArea、GarageType
室外设施	10	WoodDeckSF、PoolQC、Fence
交易信息	4	MoSold、YrSold、SaleType、SaleCondition

原始数据未在此阶段进行完整缺失插补。为计算某些探索指标而准备的临时编码或填补表，也不是最终模型的数据处理pipeline。

03 / 缺失、稀有与近常量字段审查

源Notebook单元（从0计）：单元7-9

为每个字段记录所属组、类型、训练/测试缺失数量与比例、非缺失唯一值数量，以及最常见值占比。19个训练字段至少出现过一个NA标记；缺失频率高不代表信息无用，NA也可能表示设施不存在。

字段	训练NA数	训练NA%	测试NA%
PoolQC	1453	99.52	99.79
MiscFeature	1406	96.30	96.50
Alley	1369	93.77	92.67
Fence	1179	80.75	80.12
FireplaceQu	690	47.26	50.03
LotFrontage	259	17.74	15.56
GarageType	81	5.55	5.21
GarageYrBlt	81	5.55	5.35
GarageQual	81	5.55	5.35
GarageCond	81	5.55	5.35

PoolQC、Alley、Fence、地下室和车库类字段的NA可能是“不适用/设施不存在”；LotFrontage的NA则需要单独制定插补方案。EDA仅识别并讨论这些差异，没有在这里执行之后F1-F6的正式填补规则。

98%主导值阈值：筛查候选，不直接删列

近常量/稀疏字段	最常见值占比%
Utilities	99.93
Street	99.59
PoolQC	99.52
PoolArea	99.52
Condition2	98.97
3SsnPorch	98.36
LowQualFinSF	98.22
RoofMatl	98.22

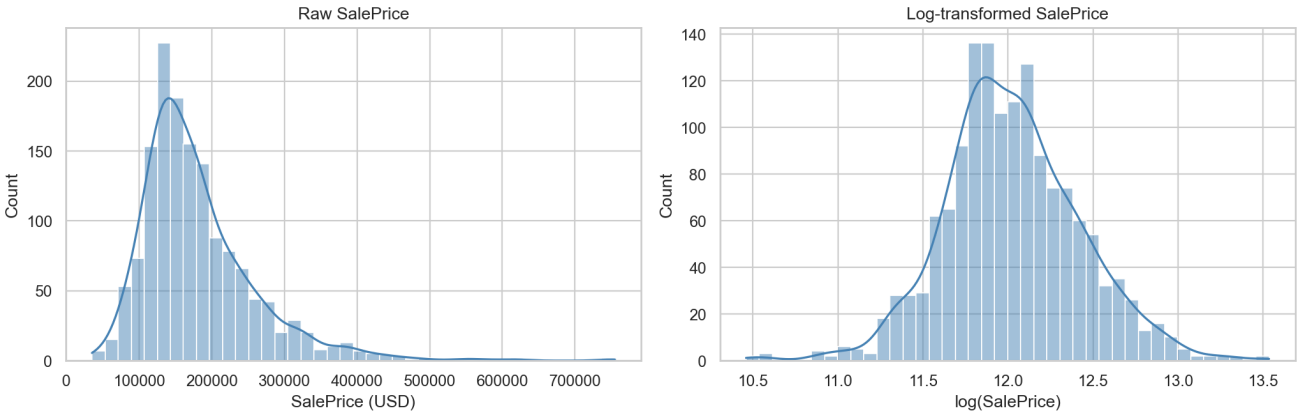
该EDA使用“最常见值占比≥98%”作审查阈值；后续特征工程方案中的99%阈值属于另一阶段，不能混为一谈。PoolQC的主导值还是缺失标记，因此不能只凭本表宣布它无预测价值。

对应输出：feature_dictionary_and_quality.csv与01_missing_markers_train.png；前者覆盖全部79列，而不是只保存图中出现的高缺失字段。

04 / SalePrice分布与数值字段的单变量关联

源Notebook单元（从0计）：单元10-14

对房价计算均值、标准差、中位数及1%、5%、25%、75%、95%、99%分位，并绘制原始与自然对数价格的直方图和KDE。目标分析保持原SalePrice不变，另建log_target=ln(SalePrice)。



原图：eda_outputs/02_target_distribution.png

统计量	原始SalePrice（美元）
均值 / 中位数	180921.20 / 163000
最小 / 最大	34900 / 755000
原价偏度 / log价偏度	1.8829 / 0.1213

原价明显右偏，取自然对数后偏度接近0，支持后续考虑log目标与Log RMSE。但没有做正式正态性检验，不能直接声称log价格服从正态分布。

35个数值字段分别计算Pearson与Spearman

字段	Pearson对log价	Spearman对log价
OverallQual	0.8172	0.8098
GrLivArea	0.7009	0.7313
GarageCars	0.6806	0.6907
GarageArea	0.6509	0.6494
TotalBsmtSF	0.6121	0.6027
1stFlrSF	0.5970	0.5754
FullBath	0.5948	0.6360
YearBuilt	0.5866	0.6527

Pearson看线性关联，Spearman看秩次上的单调关联；原代码使用可用观测对计算相关，没有先对所有数值字段统一插补。
OverallQual与GrLivArea关联突出，但低单变量相关不能证明字段无用，也不意味着因果关系。

05 / 用散点图与类别分组认识价格差异

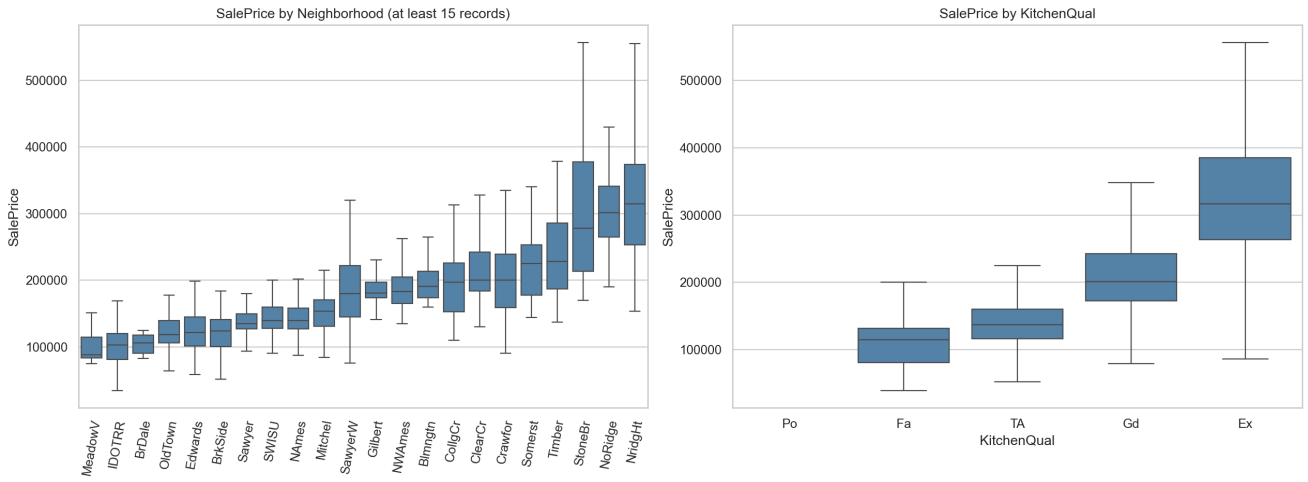
源Notebook单元（从0计）：单元14-17

数值部分画了Pearson与Spearman各前15名的条形图，并对Pearson排名前6字段绘制散点图：OverallQual、GrLivArea、GarageCars、GarageArea、TotalBsmtSF、1stFlrSF。散点图用于观察离群点、离散程度与非线性形状。

44个类别字段：eta-squared与分组价格统计

将缺失暂作__MISSING__类别，计算eta-squared=组间平方和/总平方和，目标是ln(SalePrice)。它是当前样本的描述性组间差异，不是验证准确率；类别多或组很小可能使指标偏高。

类别字段	eta-squared	类别数（含缺失）
Neighborhood	0.5708	25
ExterQual	0.4611	4
BsmtQual	0.4523	5
KitchenQual	0.4476	4
GarageFinish	0.3810	4
GarageType	0.3346	7



原图：eda_outputs/06_categorical_price_boxplots.png

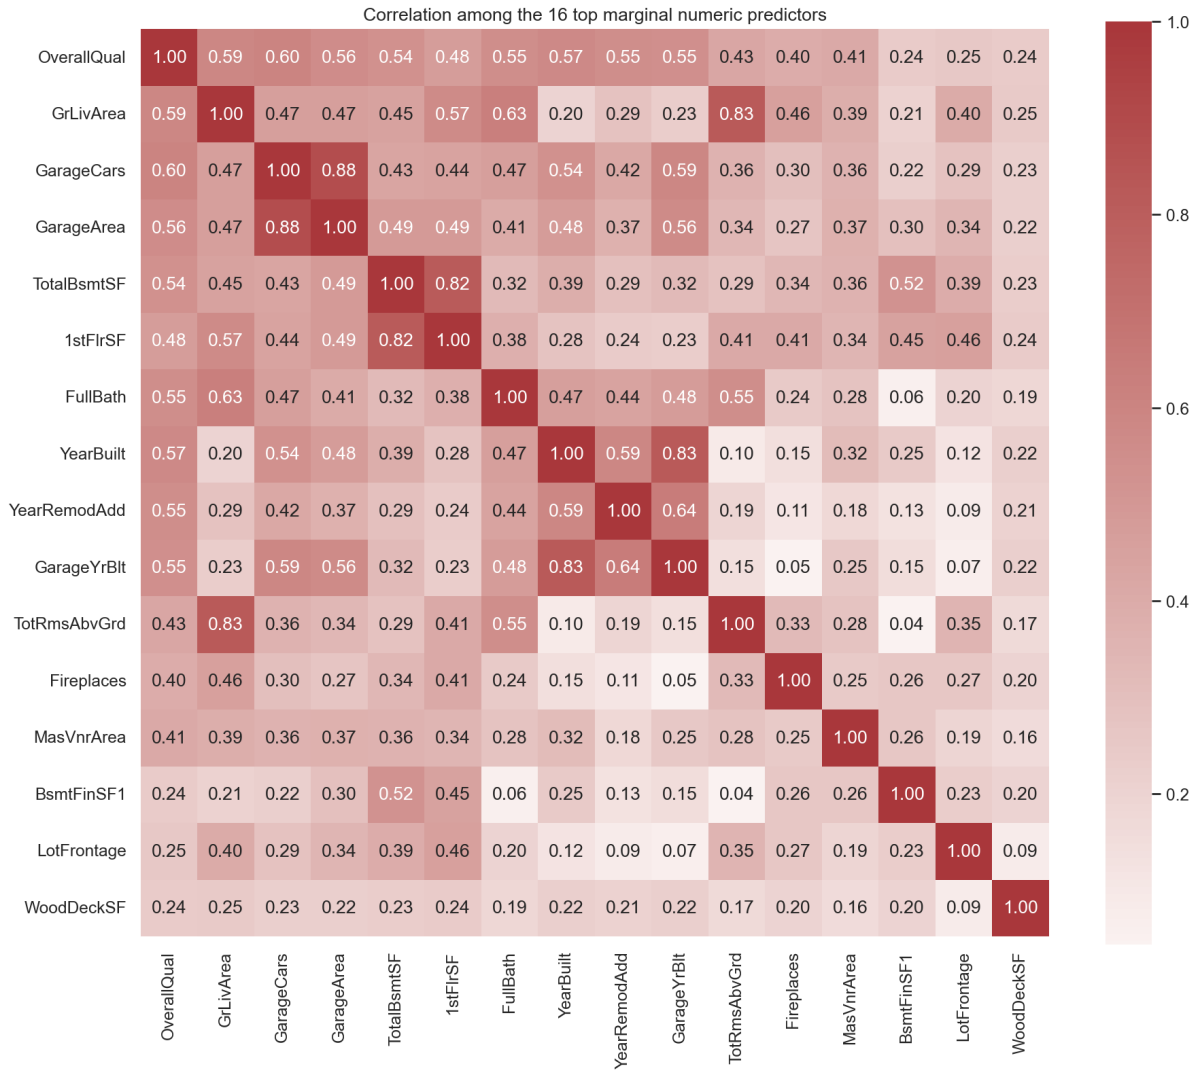
还对Neighborhood、KitchenQual、MSZoning、HouseStyle计算每组样本数、原价中位数及均值。例如NridgHt有77条、中位315000；NoRidge有41条、中位301500；厨房Ex有100条、中位316750，TA有735条、中位137000。这些是观察性差异，不能当作装修的因果收益。

社区箱线图仅展示样本数≥15的社区；showfliers=False仅隐藏图上的离群点。两者都没有从训练数据或统计表中删除对应记录。

06 / 数值字段之间的冗余与共线性

源Notebook单元（从0计）：单元18-19

对全部35个数值字段计算Pearson相关矩阵，并把595个不重复字段对按绝对相关排序保存。图中为了可读性，只展示与log房价单变量关联排名前16个数值字段，不是全部79列。



原图：eda_outputs/07_numeric_feature_correlation_matrix.png

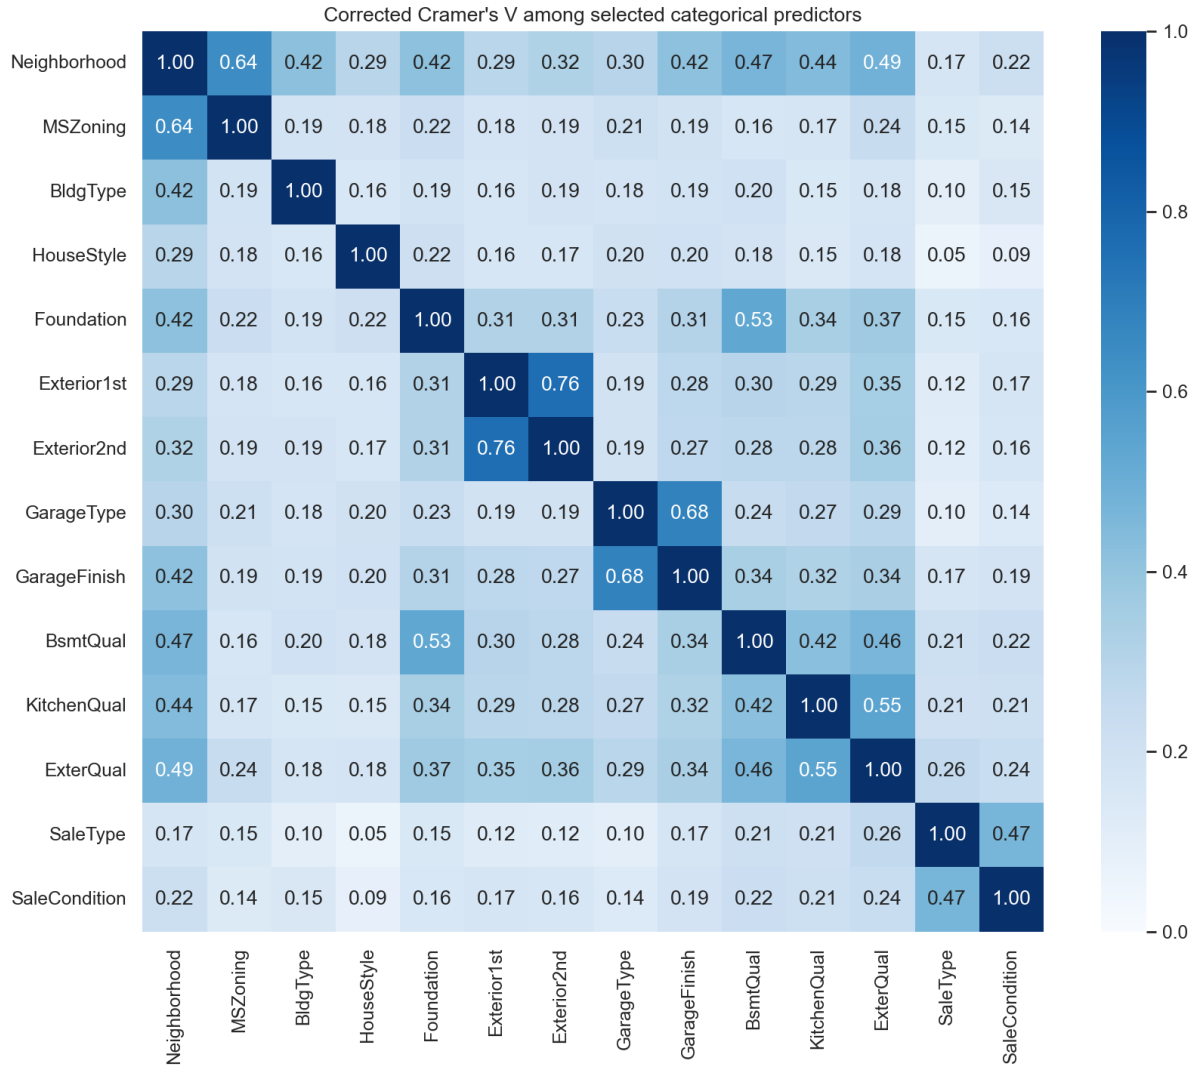
数值字段对	Pearson r
GarageCars / GarageArea	0.8825
YearBuilt / GarageYrBlt	0.8257
GrLivArea / TotRmsAbvGrd	0.8255
TotalBsmtSF / 1stFlrSF	0.8195

GarageCars和GarageArea、GrLivArea和TotRmsAbvGrd等提供了相关信息，提示后续检查冗余。不过本EDA没有按固定相关阈值实际删列；两个高度相关字段仍可能对不同模型具有增量价值。

07 / 类别字段之间的关联：校正Cramér's V

源Notebook单元（从0计）：单元20-21

选14个代表性类别字段，缺失按__MISSING__处理，用列联表和卡方统计量计算带偏差校正的Cramér's V。得到14×14对称矩阵，对角为1；并非计算了全部44个类别字段的完整矩阵。



原图：eda_outputs/08_categorical_cramers_v_heatmap.png

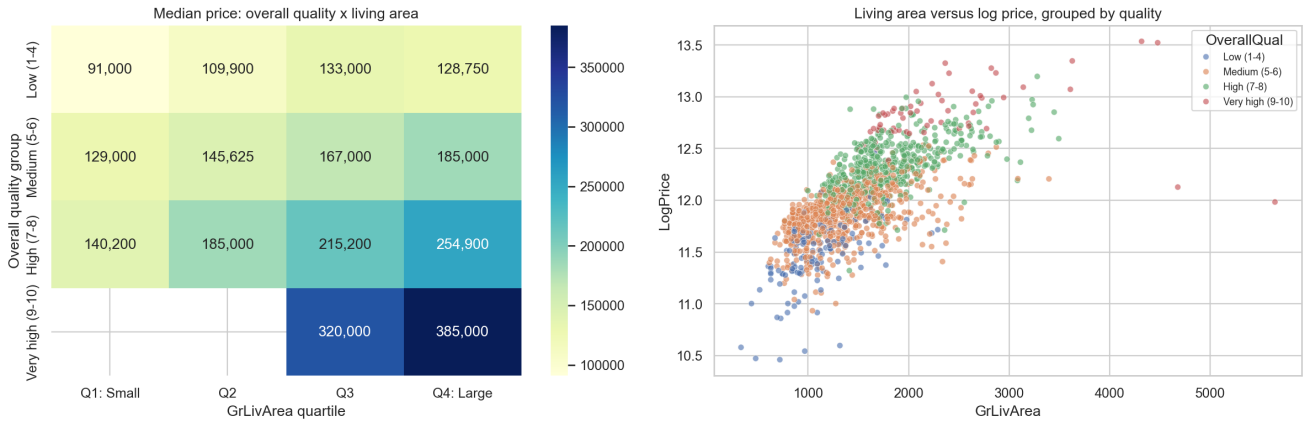
类别字段对	校正Cramér's V
Exterior1st / Exterior2nd	0.7589
GarageType / GarageFinish	0.6849
Neighborhood / MSZoning	0.6406
KitchenQual / ExterQual	0.5460

主要例子是Exterior1st/Exterior2nd约0.7589、GarageType/GarageFinish约0.6849、Neighborhood/MSZoning约0.6406。V没有方向和正负号，反映类别依赖，不证明因果，也不自动证明应删掉哪个字段。共同缺失或共有业务背景也可能贡献关联。

08 / 非线性趋势与面积×质量的交互探索

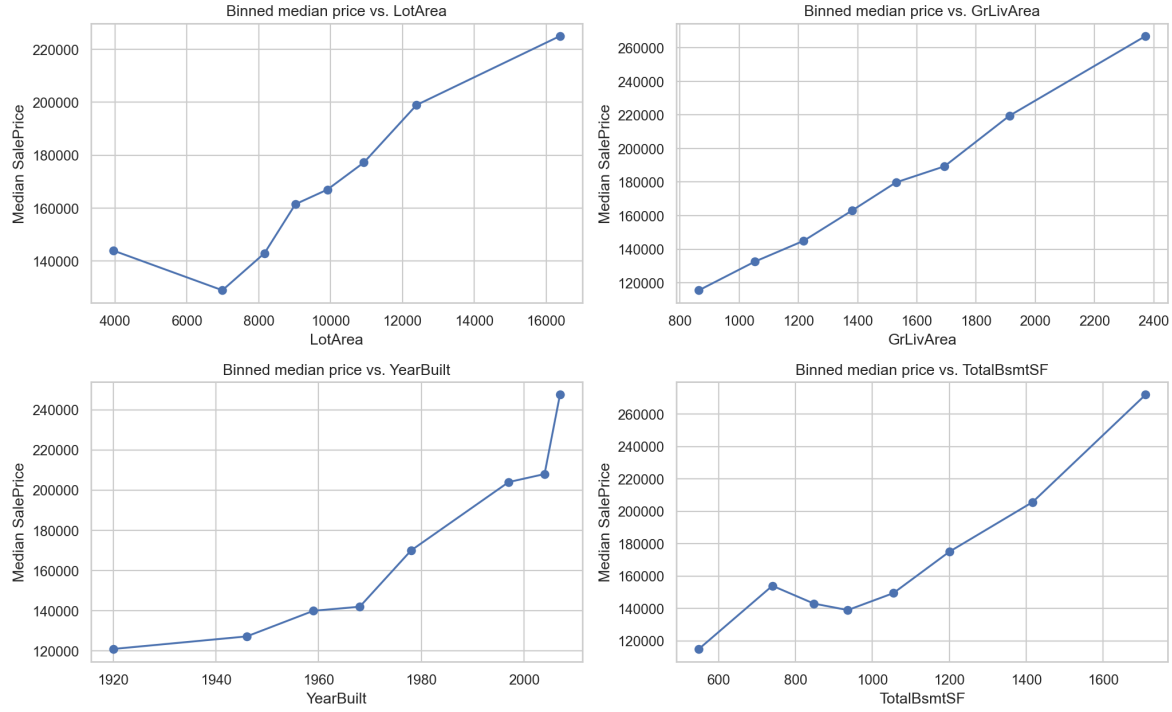
源Notebook单元（从0计）：单元22-24

把GrLivArea按qcut分成4个等频面积组，把OverallQual按[0,4,6,8,10]分为低、中、高、极高4组，计算每个实际出现组合的样本数和原价中位数。16种可能组合中出现14种；热力图与分质量散点图用于探索面积与价格的关系是否随质量组而变化。



原图：eda_outputs/09_area_quality_interaction.png

中等质量房屋由最小到最大面积组，中位价约129000→145625→167000→185000；极高质量且最大面积组有48条，中位385000。低质量最大面积组仅4条，中位128750，不能凭小组中位数断言“大面积使房价下降”。



原图：eda_outputs/10_binned_numeric_trends.png

对LotArea、GrLivArea、YearBuilt、TotalBsmtSF另做8个等频箱（重复分位点允许减少箱数），绘制每箱字段中位数与价格中位数趋势。该图支持探索非线性，而非估计因果曲线。

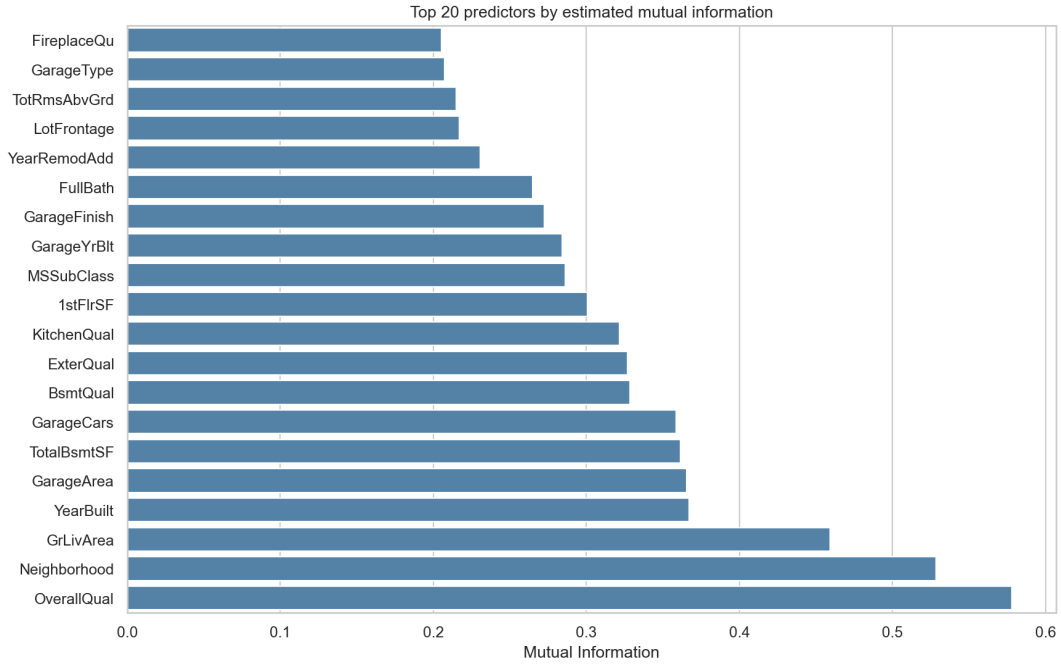
AreaGroup、QualityGroup、LogPrice只是EDA辅助列；Notebook没有在此导出QualityArea、TotalSF等最终工程特征，也没有验证某个交互项会让模型误差下降。

09 / 79列互信息与综合特征筛查表

源Notebook单元（从0计）：单元25-28

使用mutual_info_regression估计每个预测字段与ln(SalePrice)的统计依赖：n_neighbors=3、random_state=42。类别缺失转__MISSING__，factorize(sort=True)编码，并明确标为离散；编码数字没有顺序意义。数值列仅为这项估计做中位数填补（整列无有效值回退0），并统一按连续变量传入。

MI名次	字段	互信息估计
1	OverallQual	0.5781
2	Neighborhood	0.5283
3	GrLivArea	0.4590
4	YearBuilt	0.3672
5	GarageArea	0.3656
6	TotalBsmtSF	0.3616
7	GarageCars	0.3588
8	BsmtQual	0.3286
9	ExterQual	0.3269
10	KitchenQual	0.3216



原图：eda_outputs/11_mutual_information_rankings.png

随后将缺失/质量、数值Pearson与Spearman、类别eta-squared、MI及MI rank合并成feature_screening_summary.csv，保留全部79列。不同指标类型不适用的格子留空，不是0；没有把不同量纲指标直接相加，也没有仅凭MI前k名就删除其余字段。

互信息可反映非线性依赖，但估计有噪声，对样本规模、编码与连续/离散设置敏感。EDA中的全训练集排名只能提出假设；后续验证时若按目标筛选，必须每个训练折重新拟合。

10 / 训练/测试一致性与未见类别

源Notebook单元（从0计）：单元29-30

测试集没有房价标签，因此只比较可见输入信息。先比较两份表的缺失比例，计算test%-train%的百分点差；例如FireplaceQu约+2.774个百分点、LotFrontage约-2.181个百分点。这个检查提示后续插补与编码要能处理差异。

字段	测试中训练未见的状态
MSSubClass	150
MSZoning	__MISSING__
Utilities	__MISSING__
Exterior1st	__MISSING__
Exterior2nd	__MISSING__
KitchenQual	__MISSING__
Functional	__MISSING__
SaleType	__MISSING__

共8个字段出现训练未见状态，其中MSSubClass的150是真正新的有效类别；其余7个是测试中出现、训练中未出现的缺失状态。不能把本表写成“8种新房屋类型”。

本步骤能回答和不能回答什么

能支持的说明	不能据此宣称
需要支持未知类别和测试缺失	训练/测试完全同分布。
某些字段NA率不同	已经做了完整KS、PSI等漂移检验。
识别了具体类别与年份边界问题	已经利用测试标签挑选最佳特征。
测试记录仍有1459条	将异常测试样本删除后分数更好。

这些都是部署前的数据兼容性检查，不是使用隐藏测试标签评估模型。Notebook未训练预测器，也没有在这里查询Kaggle分数来筛选变量。

11 / 异常记录审查：标记，不自动删除

源Notebook单元（从0计）：单元31-32

设置四条检查：GarageYrBlt>YrSold+1；YearBuilt>YrSold；BsmtQual缺失但TotalBsmtSF>0；MasVnrType为None但MasVnrArea>0。训练集另外标记GrLivArea>4000的大面积房屋。结果保存为15条审查记录，本快照中对应15个不同Id：训练9条、测试6条。

发现类型	实际记录与现象
训练：饰面类型与面积矛盾	Id625、774、1231、1301、1335，共5条。
训练：超大地上居住面积	Id524、692、1183、1299，共4条；这是审查阈值，不是删除条件。
测试：异常建造年份	Id2593的GarageYrBlt=2207；Id2550的YearBuilt=2008但YrSold=2007。
测试：地下室描述缺失	Id2218、2219有正地下室面积但BsmtQual缺失。
测试：饰面类型与面积矛盾	Id1670、2453，共2条。

为什么不能把4栋大房屋都认定为脏数据

Id	GrLivArea平方英尺	SalePrice美元
524	4676	184750.0
692	4316	755000.0
1183	4476	745000.0
1299	5642	160000.0

Id692与1183是75万美元左右的豪宅，而Id524与1299是大面积但18万/16万美元左右的交易。异常形状可能来自特殊交易、罕见房屋或录入问题，EDA只建议调查，没有把任何一类自动删掉。

本EDA没有进一步执行后续激进清洗实验中的IQR/MAD删行、负数系统审查、训练内部OOF残差过滤或重新插补；也没有在这里修正2207等值。不能把后续阶段的措施回填成原EDA已完成的动作。

12 / 给队友的总结、文件索引与报告表述

源Notebook单元（从0计）：单元27-34

EDA形成的主要认识

房价右偏，log目标更适合后续比较；总体质量、居住面积、车库与地下室规模、社区和质量类别值得重点保留为候选；高缺失设施字段需结合业务含义；多字段存在冗余，面积关系可能非线性并随质量变化；测试集编码与缺失边界必须兼容。以上均为探索结论，需要后续模型验证。

已完成与仅建议的边界

已完成：统计、可视化、关联/互信息排名、15条异常标记及79列综合筛查表。仅在最后提出的后续建议：Ridge/树模型基线、top-k筛选、Lasso/树重要性、HouseAge/TotalSF/TotalBath/QualityArea等特征工程，以及固定CV比较。原Notebook没有实际运行这些建模实验，更没有产生后来的0.10925提交。

可改写到最终报告的表述

“本项目首先对79个原始预测变量开展探索性分析，将变量按业务含义划分为7组，检查缺失、字段类型及近常量情况。通过原价与log房价分布、数值Pearson/Spearman、类别组间差异、预测变量间关联、面积与质量分组及互信息排名，综合识别候选信号、冗余与非线性。进一步检查训练/测试缺失差异和未见类别，并将15条可疑记录保留为人工审查对象。EDA结果用于后续工程与验证设计，而非直接作为删行、删列或泛化性能结论。”

交接文件	用途
source/House_Price_EDA.ipynb	原GitHub固定版本的35单元Notebook，含已保存输出。
eda_outputs/（11张PNG、10张CSV）	原始图表和完整数值；最关键为feature_screening_summary.csv。
evidence/notebook_cell_map.csv	说明段落与原单元定位对照；编号从0计。
evidence/remote_verification.json	提交版本、文件SHA256及与本地逐字节一致性。
EDA过程中文说明.txt	本说明的可编辑文字内容，方便队友改写。

固定来源：697b337fc3ad28449f07e4b3d661a0b51e6f8bb3。后续F2-F6、80/86列筛选、TFM与异常删除实验应在报告的后续章节引用相应代码和验证结果；不要把不同阶段的阈值与样本数量混写。