HOUSE PRICES / 最佳结果交接说明

0.10925 最佳结果
数据清洗与特征工程

F2-F6逐步详解版 · 供队友撰写最终项目报告使用

整理日期：2026-11-06 | 已提交文件：submission_recommended_two_seed.csv

本文按实际提交文件、保存的模型上下文和CSV核对。截图中的准确Kaggle public log RMSE是0.10925，来源为用户提交截图，未另行访问Kaggle API。此分数对应TabPFN-2.5、8个集成成员，以及C0原86列特征流程。

最需要写对的结论

C0并不等于未清洗的原始数据。它已经执行语义清洗、异常年份处理、缺失填补、F6工程、监督筛选80列和社区背景6列。这次0.10925没有额外删除训练行、没有分位数截尾，也没有采用本轮C1条件插补。

项目	上一最佳	本次最佳
输入数据	同一套86列	同一套86列，CSV字节完全相同
模型与成员数	TabPFN-2.6 / 16	TabPFN-2.5 / 8
训练/测试行数	1460 / 1459	1460 / 1459
额外训练行删除	0	0
Kaggle public log RMSE	0.11134	0.10925

因此，0.11134到0.10925的这一步提升，应归于在相同数据下更换模型版本及推理配置的联合变化；不能写成“这次删掉异常样本提高了成绩”。绝对下降0.00209，约1.88%。

本文结构

第2节说明语义清洗；第3.1-3.7节分别详解F2-F6的公式、顺序、边界和真实样例；第4-7节说明筛选、社区特征、模型验证和数据预览；第8节说明实验与交接；附录列出完整86列。

02 / 原始数据与语义清洗：先分清“没有”和“未知”

原始 train.csv 有1460行、79列预测变量，另有Id与SalePrice；官方test.csv有1459行、79列预测变量及Id，无真实房价。原始训练/测试中分别有6965/7000个缺失单元。Id只用于对齐，SalePrice只作为目标，不进入特征列。

F1：按业务含义处理缺失与异常

处理对象	实际执行规则
房屋类型代码	将MSSubClass转成字符串，作为类别，而非连续数值。
缺失标记	只为拟合数据中出现过缺失的字段建立 *_Missing；1表示该样本原值缺失，0表示非缺失。
Alley / Fence / MiscFeature	缺失分别填为NoAlley、NoFence、NoMiscFeature，明确表示对应设施不存在。
泳池与壁炉	PoolArea=0时，缺失PoolQC填Absent；Fireplaces=0时，缺失FireplaceQu填Absent。
地下室	仅在TotalBsmtSF=0时，把缺失的地下室质量、状况、暴露、装修类型填Absent。
车库	仅在GarageCars=0且GarageArea=0时，把缺失的车库类型、装修、质量和状况填Absent。
临街长度LotFrontage	缺失值先用拟合数据中同Neighborhood的中位数填补；该社区没有统计量时回退拟合数据总体中位数。
车库建造年份	GarageYrBlt < 1800 或 > YrSold+1，标记GarageYearInvalid，并将年份置为缺失。
房屋建造年份	YearBuilt > YrSold，标记HouseYearInvalid，并将年份置为缺失。
饰面信息冲突	MasVnrType为字符串None但MasVnrArea>0时，标记MasonryConflict，并将类型改为Unknown。

Absent表示有证据说明设施不存在；Unknown表示无法确定。设施容量本身未知时，不直接认定为不存在。后续字段筛选可能移除部分标记，但它们仍是候选特征工程的一部分。

没有删除训练样本，没有修改房价标签；异常记录保留并按上述明确规则处理。整个过程不合并训练集与测试集来估计统计量。

03.1 / F2：把年份转换为房屋使用与装修状态

目的：原始年份只表示时间位置，房龄及距装修时间能更直接表达使用时长。F2接收F1语义清洗后的表；此时非法YearBuilt与GarageYrBlt已被置为NaN。以下四列全部先作为候选特征构造，不代表都会保留。

字段 / 单位	公式与执行条件	业务含义
HouseAge / 年	YrSold - YearBuilt	销售时房屋使用年数；YearBuilt未知则结果未知。
YearsSinceRemodel / 年	仅YrSold >= YearRemodAdd时，计算YrSold - YearRemodAdd；否则NaN。	距最近一次记录装修的时间。
HasRemodel / 0或1	1[YearRemodAdd > YearBuilt]；其余为0。	是否存在晚于建造年的装修记录。
GarageAge / 年	非“GarageCars=0且GarageArea=0”，且YrSold >= GarageYrBlt时计算两年份之差；否则NaN。	车库使用时间，可能与房屋房龄不同。

真实样例：Id=1

该样本YrSold=2008、YearBuilt=2003、YearRemodAdd=2003、GarageYrBlt=2003，且有车库。

输出	实际计算	工程阶段结果
HouseAge	2008 - 2003	5
YearsSinceRemodel	2008 - 2003	5
HasRemodel	2003 > 2003为假	0
GarageAge	2008 - 2003	5

缺失与边界必须照实际代码解释

没有车库时GarageAge先设NaN，并不是直接填0；到统一FrameImputer步骤，会按训练数据中位数填补。装修年份晚于销售年时，不把负年数强行改为0，而是保持未知后填补。HasRemodel使用直接布尔比较，未知值参与比较通常为假，因此其0不能在所有情况下解释为“已证实未装修”。

最终全量筛选保留YearsSinceRemodel、HasRemodel、GarageAge；HouseAge因与已选YearBuilt高度相关而未保留。这个决策来自最终1460行拟合；CV每个训练折会重新筛选，不能预先固定同样的删列结论。

03.2 / F3：面积、卫浴合计与设施存在标记

目的：把分散在多个字段中的房屋规模和设施信息汇总。所有合计先在原始尺度计算，不在对数尺度相加；本阶段不使用SalePrice。

聚合字段	实际组成	未知时的规则
TotalSF	TotalBsmtSF + 1stFlrSF + 2ndFlrSF	三项必须都有值；任一未知，合计为NaN（min_count=3）。
TotalBath	FullBath + 0.5×HalfBath + BsmtFullBath + 0.5×BsmtHalfBath	普通加法传播NaN；不将未知卫浴数当作0。
TotalOutdoorSF	WoodDeckSF + OpenPorchSF + EnclosedPorch + 3SsnPorch + ScreenPorch	五项都已知才求和（min_count=5）。

TotalSF没有再加GrLivArea，以免把地上面积重复计入；代码没有把LowQualFinSF作为第四项加入；因此此处是指定三项合计，不能与TotalBsmtSF+GrLivArea无条件画等号。TotalOutdoorSF不含PoolArea。TotalBath中的0.5是半卫浴的特征权重，不表示有半个物理房间。三项合计在最终80列中都保留，但面积类随后在F5取log1p。

六个Has设施标记：由对应容量判断

标记	判定来源	规则
HasGarage	GarageCars	对应值>0则1，等于0则0；原值缺失则NaN。
HasBasement	TotalBsmtSF	同上。
HasFireplace	Fireplaces	同上。
HasPool	PoolArea	同上。
HasSecondFloor	2ndFlrSF	同上。
HasMasonry	MasVnrArea	同上。

Id=1的真实合计结果

TotalSF = 856 + 856 + 854 = 2566平方英尺；TotalBath = 2 + 0.5×1 + 1 + 0.5×0 = 3.5；TotalOutdoorSF = 0 + 61 + 0 + 0 + 0 = 61平方英尺。

最终六个Has设施标记均未保留：其中五个被判为与已选面积/质量字段冗余，HasPool未进入80列预算。构造标记的目的在于提供候选信号，不意味着模型最后实际使用了这六列。缺失合计后续单独填补，因此不能宣称填补后的总量一定等于各项代理数值之和。

03.3 / F4：用质量与面积构造交互项

目的：相同居住面积在不同建筑质量下，可能对应不同价格关系。F4显式增加两个“规模×质量”候选，让模型更容易接触这种组合信息；这是一项特征设计，并不证明价格与该乘积存在因果或严格线性关系。

字段	F4原始尺度公式	参与计算的输入
QualityArea	OverallQual × GrLivArea	总体质量原数值 × 地上居住面积原数值。
QualityTotalSF	OverallQual × TotalSF	总体质量原数值 × F3刚计算的总面积。

Id=1：先乘，再在F5取log1p

字段	F4计算值	F5最终表示
QualityArea	7 × 1710 = 11970	ln(11970+1) = 9.390242
QualityTotalSF	7 × 2566 = 17962	ln(17962+1) = 9.796069

不能把此步骤写成“先对面积取log，再乘质量”，两种结果不同；也不是对已经取log的QualityArea再做一次log。最终两个交互项都保留，OverallQual和相应面积字段也保留各自的表示。

从执行顺序理解列的数值含义

位置	数据所处尺度
F1-F3	语义清洗、时间特征、面积与卫浴合计；面积仍为平方英尺。
F4	先在上述尺度生成QualityArea与QualityTotalSF。
F5	只对预设面积、金额与交互字段做ln(1+x)，替换其原表示。
F6	另走未log1p的语义分支计算比例；不是从F5列相除恢复比例。
填补与筛选	在当前表示上拟合填补与重要性；最后只留80列，再加社区6列。

若任一乘数未知，乘积也保持NaN，再由训练拟合的填补器处理。OverallQual在这里仍使用原始质量评分，未参与F5的Po/Fa/TA/Gd/Ex类别映射。两个乘积的量纲是“质量分×面积”，不应把乘积本身称为真实建筑面积。

03.4 / F5：质量类别有序编码

F5有两项独立变换：质量有序编码和预设字段log1p。它们是对已有字段的替换，不是把原始字符串与编码值都加进最终表。以下先解释质量编码。

原始类别	Absent	Po	Fa	TA	Gd	Ex
编码值	0	1	2	3	4	5

Absent表示设施确定不存在，来源于F1依据容量判断；Po/Fa/TA/Gd/Ex依次表示差、较差、一般、较好、优秀。未知或其他不在映射中的值先记NaN，另建“原字段名_Unknown”标记；最终数值按训练中位数填补。

10个被编码字段与最终保留状态

字段	含义	最终86列状态
ExterQual	外部材料质量	保留
ExterCond	外部维护状况	未保留
BsmtQual	地下室高度/质量	保留
BsmtCond	地下室维护状况	保留
HeatingQC	供暖质量	保留
KitchenQual	厨房质量	保留
FireplaceQu	壁炉质量	保留
GarageQual	车库质量	保留
GarageCond	车库维护状况	未保留
PoolQC	泳池质量	未保留

实例及需要区分的情形

Id=1的ExterQual为Gd，故编码为4。没有壁炉且质量缺失的房屋，F1先填Absent，F5再编码为0；容量信息未知时不能擅自填Absent。Unknown标记在填补前生成，填补后仍记录原先不确定性。中位数填补有时可产生非整数，不能说所有输出质量值都必然为0-5整数。

OverallQual、OverallCond本来就是数值评分，保留原数值；BsmtFinType1、GarageFinish、Neighborhood等不在这10列里的类别保持字符串，不能称为“所有类别都被有序编码”。本次10个质量_Unknown候选标记均未进入最终80列。

03.5 / F5：偏态字段的log1p变换

目的：压缩少量极大值相对主体数据的数值跨度，同时允许0。执行z=ln(1+x)，x=0时z=0，x<0先转NaN；不是ln(x)、标准化、分位截尾或删行。下面23列是固定候选清单；其中20列进入最终80列。

序号	变换字段	最终86列状态
1	LotFrontage	保留
2	LotArea	保留
3	MasVnrArea	保留
4	BsmtFinSF1	保留
5	BsmtFinSF2	保留
6	BsmtUnfSF	保留
7	TotalBsmtSF	保留
8	1stFlrSF	保留
9	2ndFlrSF	保留
10	LowQualFinSF	未保留
11	GrLivArea	保留
12	GarageArea	保留
13	WoodDeckSF	保留
14	OpenPorchSF	保留
15	EnclosedPorch	保留
16	3SsnPorch	未保留
17	ScreenPorch	保留
18	PoolArea	未保留
19	MiscVal	保留
20	TotalSF	保留
21	TotalOutdoorSF	保留
22	QualityArea	保留
23	QualityTotalSF	保留

Id=1：LotArea的8450变为ln(8451)=9.042040；TotalSF的2566变为ln(2567)=7.850493。这里Area/SF字段名没有改名，但数值已不是原始平方英尺。

年份、卫浴计数、质量分及F6比例不在此清单中，不统一取对数。目标房价另用ln(SalePrice)；不能与输入字段的ln(1+x)混淆。输出预测只需对log房价取exp，不对输入表逐列“反变换”。

03.6 / F6：原始尺度的比例与交互

F6保留F5结果作为主表，同时重新使用F4_interaction语义分支，得到尚未做log1p、也未做F5质量编码的数值。以下六项均从这份原始尺度表计算，随后追加到F5主表。

新增候选	原始尺度公式	含义与单位
LivLotRatio	GrLivArea / LotArea	居住面积与地块面积比；无单位，可大于1，不硬裁到[0,1]。
BsmtFinishRatio	(BsmtFinSF1 + BsmtFinSF2) / TotalBsmtSF	地下室已装修面积占比；分量必须已知。
FirstFloorRatio	1stFlrSF / GrLivArea	一层占地上居住面积的比例。
QualityCondition	OverallQual × OverallCond	质量与维护评分的交互；不再log1p。
GarageAreaPerCar	GarageArea / GarageCars	平均每车位面积代理；平方英尺/车位。
RelativeLivingArea	GrLivArea / 同社区GrLivArea训练中位数	相对社区居住面积；未知社区回退训练总体中位数。

Id=1的六个真实候选结果

字段	实际计算	结果
LivLotRatio	1710 / 8450	0.202367
BsmtFinishRatio	(706 + 0) / 856	0.824766
FirstFloorRatio	856 / 1710	0.500585
QualityCondition	7 × 5	35.000000
GarageAreaPerCar	548 / 2	274.000000
RelativeLivingArea	1710 / 1500	1.140000

CollgCr的1500是本次完整训练数据中该社区GrLivArea的中位数；CV时只能用当前训练折的社区统计。已有RelativeLivingArea与后续新六列中的RelativeLotArea关注不同面积，不能混写成同一个特征。

示例中LivLotRatio=1710/8450，而不是7.444833/9.042040。后者是两个log1p数值之比，既不符合此代码，也失去了原始面积比例含义。

03.7 / F6：零分母、未知值与最终取舍

通用ratio(a,b)仅在b>0时计算a/b，其他情况先返回NaN；无穷值也转为NaN。对地下室和车库，只有下面明确满足“不存在”条件时才另外设为0。未知与确定不存在必须区分。

情形	工程值及标记	统一填补后
地下室总面积和两类已装修面积均为0	BsmtFinishRatio=0；_Unknown=0。	保持0。
地下室分母无效，或分子信息不全，且不满足上述不存在条件	BsmtFinishRatio=NaN；_Unknown=1。	BsmtFinishRatio填-1。
GarageArea=0且GarageCars=0	GarageAreaPerCar=0；_Unknown=0。	保持0。
车位数无效或车库面积未知，且不满足上述不存在条件	GarageAreaPerCar=NaN；_Unknown=1。	GarageAreaPerCar填-1。

F6总共追加8个候选列，最终保留5个

F6候选字段	最终状态 / 原因
LivLotRatio	保留
BsmtFinishRatio	保留
FirstFloorRatio	未保留：与已选2ndFlrSF高度相关
QualityCondition	保留
GarageAreaPerCar	保留
RelativeLivingArea	保留
BsmtFinishRatio_Unknown	未保留：最终训练集中为常量
GarageAreaPerCar_Unknown	未保留：最终训练集中为常量

FirstFloorRatio与2ndFlrSF的“冗余”是当前训练数据上的关联判定，并非两者公式相同。两个Unknown标记虽然在完整训练筛选中被剔除，仍属于生成和判断未知值的中间字段；每折筛选结果可能不同。

FrameImputer接在工程之后、筛选之前

其余数值NaN按当前训练表该字段中位数填补；整列无有效值时回退0。中位数在当前表示上计算：F5面积字段已为log1p尺度，F6比例仍为原始比值。类别缺失填Unknown，保持字符串。填补器只fit训练行，再transform验证/测试行，最后才筛选80列并追加社区6列。

最终仍为80+6=86列；F2-F6构造过的字段不能全部当作最终输入。这里没有增加额外删行、Winsorization、原始层条件插补或新的目标编码，0.10925对应的数据及模型配置均保持不变。

04 / 怎样从候选特征中得到原Dataset 2的80列

使用SelectedFeatures(scheme="F6_enhanced", k=80, near_constant=0.99, compact=False, seed=42)。监督筛选的目标为自然对数房价ln(SalePrice)。最终全量拟合生成134个候选字段，按如下步骤筛选。

① 在拟合数据内部再做三折评分

内部KFold=3、shuffle=True、random_state=314。每个内折单独拟合工程与填补，再从三个角度评价每个字段：

评分来源	实现方式
互信息MI	衡量单个字段与ln(SalePrice)的非线性关联；类别因子化、低基数数值作离散处理，n_neighbors=3。
随机森林重要性	120棵树，min_samples_leaf=3、max_features=0.8；one-hot后的各子列重要性汇总回原字段。
Ridge置换重要性	Ridge(alpha=30)；在内折验证样本中打乱整个字段两次，记录log房价均方误差的增量。类别对应的one-hot列一起打乱。

每种评分先将负值截为0，再把正值转为百分位排名；三种排名的平均值作为字段得分，随后跨三个内折取平均。本方案compact=False，不使用“前40出现频率”的额外加权。

② 再按稳定性和冗余约束保留最多80列

按综合得分降序、互信息降序排序；剔除常量。最大类别占比≥99%的近常量字段通常剔除，但MI或森林排名达到75百分位、或置换增益超过两倍置换标准差时可保留。数值用Pearson相关、类别用校正Cramér's V；关联绝对值≥0.95的候选若与已选字段冲突，优先保留排名更高者。达到80列后停止增加。

最终全量拟合的筛选结果	字段数
保留	80
常量	14
弱信号近常量	7
与已选字段高度冗余	20
超过80列预算	13
候选合计	134

这些数量对应最终1460行拟合；交叉验证时每个训练折独立重新筛选，其字段集合可能不同。完整评分与每列决策已输出feature_selection_audit.csv。

05 / 继承的六个社区背景特征

分组键为原始Neighborhood。只从当前拟合数据中，分别计算原始OverallQual、LotArea、YearBuilt在每个社区的中位数。未知社区或社区统计缺失时，回退当前拟合数据的总体中位数。以下六列不使用SalePrice，也没有做目标均值编码。

新增字段	定义及含义
CommunityMedian_OverallQual	同社区OverallQual中位数：社区整体建筑质量参照。
CommunityMedian_LotArea	同社区原始LotArea中位数：社区典型地块面积，单位平方英尺。
CommunityMedian_YearBuilt	同社区原始YearBuilt中位数：社区典型建造年份。
RelativeQuality	原始OverallQual / CommunityMedian_OverallQual。大于1表示高于社区质量中位水平。
RelativeLotArea	原始LotArea / CommunityMedian_LotArea。大于1表示地块大于社区典型水平。
CommunityYearDifference	原始YearBuilt - CommunityMedian_YearBuilt。正值表示建造年份较新；单位为年，并非比值。

真实计算示例：训练样本Id=1

该房屋位于CollgCr；最终训练数据中该社区有150条房屋记录。原始质量7分、地块8450平方英尺、建造于2003年。最终全量拟合的社区中位数为质量7、地块9356平方英尺、建造年份2002。

输出字段	实际计算	输出值
RelativeQuality	7 / 7	1.000000
RelativeLotArea	8450 / 9356	0.903164
CommunityYearDifference	2003 - 2002	1

这里的8450来自原始LotArea，不是旧80列里已经取过log1p的LotArea。新六列直接追加，不再对数化。相较旧F6中的RelativeLivingArea，这六列补充的是质量、地块大小和建造年份的社区背景，不是重复添加同一个居住面积比。

实现细节：这六列按当前代码直接读取原始三列；不会先套用旧F1的异常年份修正规则。这是本次实际数据版本的定义，后续若改变应另建版本并重新验证。

06 / 从86列到0.10925：模型、验证与预测

实际模型配置

配置项	实际值
预训练回归模型	TabPFN-2.5；显式ModelVersion(v2.5)
推理视图 / 随机种子	n_estimators=8；random_state=42
设备 / 精度	本次运行Apple MPS；torch.float32
输入预处理	原生DataFrame，29类别保留字符串；n_preprocessing_jobs=1
其他固定选项	ignore_pretraining_limits=True；predict(output_type="mean")
目标与还原	ln(SalePrice)减训练均值12.024050901109；预测加回均值后取exp

表中目标均值只用于最终1460行拟合；CV时每个训练折独立计算均值。最终使用全部1460条训练记录拟合，再预测完整1459条官方测试数据。8个集成成员是模型推理视图数，不是8折，也不是8种模型的手工融合。未做额外预测裁剪、残差面积校正或exp偏差修正。

全样本五折：每次1168条训练、292条验证

本地评价 / 线上结果	TabPFN-2.6 C0 / 16	本次TabPFN-2.5 C0 / 8
KFold5种子2027均值	0.107397	0.106591
KFold5种子2028均值	0.105901	0.104652
两次五折均值	0.106649	0.105622
Kaggle public截图	0.11134	0.10925

每折从原始字段重新拟合清洗、统计、内部三折筛选和社区中位数，验证行只应用训练规则；所有验证行完整保留。CV均值是五折RMSE的算术平均，合并OOF RMSE另见配套逐折结果，二者不是同一个统计量。

0.10925方案是综合2027与2028后推荐的C0，因此2028参与了方案选择，不能再称为这项最终推荐的独立确认。Kaggle public也不是private leaderboard最终成绩；分数下降不能作为普遍泛化或因果效果的证明。

07 / 最终数据预览与读取方式

训练表1460行×88列 = Id + 86输入 + SalePrice；测试表1459行×87列 = Id + 86输入。以下取最终导出数据的前3条训练记录。为保证可读性分为两张表，所有值均来自CSV。

Id	社区	质量	LotArea*	建造年	房价美元
1	CollgCr	7	9.042040	2003	208500
2	Veenker	6	9.169623	1976	181500
3	CollgCr	7	9.328212	2001	223500

* 此表LotArea已是ln(1+原始地块面积)：例如Id=1的8450变为9.042040。年份与目标价格不取该对数；新增社区地块中位数仍为原始单位。

Id	社区质量中位	社区地块中位	社区建造年中位	相对质量	相对地块	年份差
1	7	9356	2002	1.000	0.903164	1
2	6	11120	1978	1.000	0.863309	-2
3	7	9356	2002	1.000	1.202437	-1

交付目录与读取

交接包data/raw/保留原始train.csv与test.csv；data/processed/保存最终86列train.csv、test.csv、schema、字段字典和筛选审计。submission/保存已提交的CSV。原始数据与处理后数据使用相同Id对齐，目标价格未修改。

推荐读取：
pd.read_csv(path, keep_default_na=False, na_values=["NA", ""], dtype={"MSSubClass": str})
这样可以保留字符串None等有效类别，防止Pandas默认把它们识别为缺失。MSSubClass还需显式保留字符串类别，而非让CSV读取器恢复为整数。用此方式核验，两张完整表均无实际缺失单元。

可用于项目报告的表述

“本项目基于原始79个预测字段，进行设施语义填补、异常年份识别、房龄与面积合计构造、交互项和预设log1p变换，并以内部三折的多指标重要性及冗余约束筛选80列。在此基础上加入6个不使用房价的社区中位数及相对指标，形成86列输入。最终保留全部1460条训练样本，以TabPFN-2.5的8个集成成员预测1459条测试记录，Kaggle public log RMSE达到0.10925。该提交没有额外采用激进训练行删除或截尾；与0.11134方案的数据完全相同，末轮提升对应模型版本与推理配置的变化。”

不要将submission_aggressive_best.csv与已提交的submission_recommended_two_seed.csv混淆：前者是2027初选的C1版本，后者才是本次截图0.10925对应的C0版本。

08 / 实验取舍、证据与队友交接

为什么最终没有采用激进删行

本轮实际完成7个模型/版本、71组完整五折，共355折。C1比较错误值修正与全局/条件插补；C2加0.995上分位截尾；C3比较上限0.5%、1%、2%的训练行过滤；C4按消融选择组合。行过滤只作用于训练折，由内部OOF残差及稳健特征异常共同决定，不按Id直接删除，也没有删验证/测试行。

七模型×三档删行的21组初筛比较均劣于同模型C0。TabPFN-2.5的C1在2027略优于C0（0.106540对0.106591），但2028反而略差（0.104869对0.104652）。两次划分综合后推荐C0；这支持保留原流程，不支持把这次线上提升归因于更激进清洗。结论仅适用于本轮已测试规则。

交接包内容与复现入口

目录 / 文件	用途
output/pdf/	本说明PDF，共18页。
data/raw/、data/processed/	原始数据、最终86列、中文/原始字段字典、筛选评分与决策。
code/legacy/、code/pipeline.py	原始工程和筛选代码的冻结副本；最终C0六个社区特征的精简实现。
code/reproduce.py	从原始数据重建86列；可选加载固定权重复现预测。
submission/	唯一对应截图0.10925的提交文件。
evidence/	实际模型配置、固定权重信息、十个本模型验证折及OOF预测、截图和历史实验记录。
verification/	本次交接代码的特征重建、模型预测复现检查。

复现特征：python code/reproduce.py。完整模型预测加--predict --checkpoint 本机权重路径 --device mps。权重与虚拟环境未打包；固定repo、revision、SHA256与环境版本见evidence/checkpoint.json及code/requirements.txt。

证据中的历史posthoc_recommendation记录仍有new_kaggle_score=null，表示当时尚未提交；本次已知成绩以best_run_config.json和截图为准。静态86列已利用完整训练标签做筛选，只供最终拟合与检查；CV必须每折重新fit整个pipeline。

09 / 附录：完整86列字段字典（1/4）

顺序与最终CSV一致；第1-80列继承Dataset 2，第81-86列为此前已加入的社区特征。Id和SalePrice不属于86列输入。详细机器可读字典另附CSV。

序号	字段名	类型	中文含义与实际处理
1	TotalSF	数值	总建筑面积；地下室+一层+二层面积，再ln(1+x)
2	QualityTotalSF	数值	质量与总面积交互；OverallQual×原始总面积，再ln(1+x)
3	QualityArea	数值	质量与居住面积交互；OverallQual×原始居住面积，再ln(1+x)
4	GarageCars	数值	车库可容车辆数；保留数值尺度；剩余未知按拟合数据中位数填补
5	QualityCondition	数值	质量与维护状况交互；OverallQual×OverallCond，原尺度
6	OverallQual	数值	总体质量评分；保留数值尺度；剩余未知按拟合数据中位数填补
7	GrLivArea	数值	地上居住面积；非负原值ln(1+x)，剩余未知填补
8	1stFlrSF	数值	一层面积；非负原值ln(1+x)，剩余未知填补
9	Neighborhood	类别	社区名称；保留语义处理后类别；剩余未知填Unknown
10	LotArea	数值	地块面积；非负原值ln(1+x)，剩余未知填补
11	YearBuilt	数值	建造年份；原始年份；晚于销售年则置缺失后填补
12	RelativeLivingArea	数值	相对社区居住面积；原始居住面积/拟合数据同社区居住面积中位数
13	TotalBsmtSF	数值	地下室总面积；非负原值ln(1+x)，剩余未知填补
14	YearsSinceRemodel	数值	距上次装修年数；YrSold-YearRemodAdd；无效时未知后填补
15	BsmtQual	数值	地下室高度质量；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
16	KitchenQual	数值	厨房质量；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
17	TotalBath	数值	加权卫浴总数；全卫浴+0.5×半卫浴；含地上与地下室
18	OverallCond	数值	总体维护评分；保留数值尺度；剩余未知按拟合数据中位数填补
19	BsmtFinSF1	数值	地下室第一类装修面积；非负原值ln(1+x)，剩余未知填补
20	MSZoning	类别	用地类别；保留语义处理后类别；剩余未知填Unknown
21	GarageArea	数值	车库面积；非负原值ln(1+x)，剩余未知填补
22	BsmtFinishRatio	数值	地下室已装修比例；已装修地下室面积/地下室总面积；不存在0，未知-1

10 / 附录：完整86列字段字典（2/4）

顺序与最终CSV一致；第1-80列继承Dataset 2，第81-86列为此前已加入的社区特征。Id和SalePrice不属于86列输入。详细机器可读字典另附CSV。

序号	字段名	类型	中文含义与实际处理
23	2ndFlrSF	数值	二层面积；非负原值ln(1+x)，剩余未知填补
24	FireplaceQu	数值	壁炉质量；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
25	TotRmsAbvGrd	数值	地上房间总数；保留数值尺度；剩余未知按拟合数据中位数填补
26	HeatingQC	数值	供暖质量；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
27	CentralAir	类别	中央空调；保留语义处理后类别；剩余未知填Unknown
28	LotFrontage	数值	临街长度；同社区中位数填补，再ln(1+x)
29	SaleCondition	类别	交易条件；保留语义处理后类别；剩余未知填Unknown
30	GarageQual	数值	车库质量；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
31	Foundation	类别	地基类型；保留语义处理后类别；剩余未知填Unknown
32	ExterQual	数值	外部材料质量；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
33	MSSubClass	类别	住宅类型代码；原整数住宅类型转为类别字符串
34	BsmtUnfSF	数值	地下室未装修面积；非负原值ln(1+x)，剩余未知填补
35	BsmtFinType1	类别	地下室第一装修类型；保留语义处理后类别；剩余未知填Unknown
36	HalfBath	数值	地上半卫浴数；保留数值尺度；剩余未知按拟合数据中位数填补
37	FullBath	数值	地上全卫浴数；保留数值尺度；剩余未知按拟合数据中位数填补
38	BsmtExposure	类别	地下室暴露情况；保留语义处理后类别；剩余未知填Unknown
39	TotalOutdoorSF	数值	室外平台总面积；五项室外平台/门廊面积相加，再ln(1+x)
40	GarageType	类别	车库类型；保留语义处理后类别；剩余未知填Unknown
41	WoodDeckSF	数值	木平台面积；非负原值ln(1+x)，剩余未知填补
42	OpenPorchSF	数值	开放门廊面积；非负原值ln(1+x)，剩余未知填补
43	LivLotRatio	数值	居住面积与地块比；原始GrLivArea / 原始LotArea
44	Fireplaces	数值	壁炉数；保留数值尺度；剩余未知按拟合数据中位数填补

11 / 附录：完整86列字段字典（3/4）

顺序与最终CSV一致；第1-80列继承Dataset 2，第81-86列为此前已加入的社区特征。Id和SalePrice不属于86列输入。详细机器可读字典另附CSV。

序号	字段名	类型	中文含义与实际处理
45	SaleType	类别	销售类型；保留语义处理后类别；剩余未知填Unknown
46	Exterior1st	类别	主要外墙材料；保留语义处理后类别；剩余未知填Unknown
47	GarageFinish	类别	车库装修水平；保留语义处理后类别；剩余未知填Unknown
48	Condition1	类别	主要邻近条件；保留语义处理后类别；剩余未知填Unknown
49	KitchenAbvGr	数值	地上厨房数；保留数值尺度；剩余未知按拟合数据中位数填补
50	GarageAge	数值	车库年龄；有效且有车库时YrSold-GarageYrBlt，再填补
51	PavedDrive	类别	车道铺装类型；保留语义处理后类别；剩余未知填Unknown
52	GarageAreaPerCar	数值	每车位车库面积；车库面积/车位数；不存在0，未知-1
53	MasVnrArea	数值	饰面面积；非负原值ln(1+x)，剩余未知填补
54	Functional	类别	房屋功能状况；保留语义处理后类别；剩余未知填Unknown
55	ScreenPorch	数值	纱窗门廊面积；非负原值ln(1+x)，剩余未知填补
56	EnclosedPorch	数值	封闭门廊面积；非负原值ln(1+x)，剩余未知填补
57	Exterior2nd	类别	次要外墙材料；保留语义处理后类别；剩余未知填Unknown
58	MasVnrType	类别	饰面类型；None且饰面面积>0时改Unknown
59	BedroomAbvGr	数值	地上卧室数；保留数值尺度；剩余未知按拟合数据中位数填补
60	Fence	类别	围栏质量；原始类别；缺失填NoFence
61	LotConfig	类别	地块配置；保留语义处理后类别；剩余未知填Unknown
62	YrSold	数值	销售年份；保留数值尺度；剩余未知按拟合数据中位数填补
63	LandContour	类别	地势；保留语义处理后类别；剩余未知填Unknown
64	LotShape	类别	地块形状；保留语义处理后类别；剩余未知填Unknown
65	BsmtCond	数值	地下室维护状况；Absent/Po/Fa/TA/Gd/Ex→0/1/2/3/4/5；未知填补
66	HouseStyle	类别	房屋风格；保留语义处理后类别；剩余未知填Unknown

12 / 附录：完整86列字段字典（4/4）

顺序与最终CSV一致；第1-80列继承Dataset 2，第81-86列为此前已加入的社区特征。Id和SalePrice不属于86列输入。详细机器可读字典另附CSV。

序号	字段名	类型	中文含义与实际处理
67	BsmtFullBath	数值	地下室全卫浴数；保留数值尺度；剩余未知按拟合数据中位数填补
68	BldgType	类别	建筑类型；保留语义处理后类别；剩余未知填Unknown
69	Electrical	类别	电气系统；保留语义处理后类别；剩余未知填Unknown
70	BsmtFinType2	类别	地下室第二装修类型；保留语义处理后类别；剩余未知填Unknown
71	LotFrontage_Missing	数值	原临街长度缺失标记；原值缺失=1，非缺失=0
72	RoofStyle	类别	屋顶风格；保留语义处理后类别；剩余未知填Unknown
73	MiscVal	数值	其他设施价值；非负原值ln(1+x)，剩余未知填补
74	Heating	类别	供暖类型；保留语义处理后类别；剩余未知填Unknown
75	BsmtFinSF2	数值	地下室第二类装修面积；非负原值ln(1+x)，剩余未知填补
76	LandSlope	类别	坡度；保留语义处理后类别；剩余未知填Unknown
77	HasRemodel	数值	是否曾装修；1[YearRemodAdd>YearBuilt]
78	Alley	类别	巷道类型；原始类别；缺失填NoAlley
79	Fence_Missing	数值	原围栏缺失标记；原值缺失=1，非缺失=0
80	MoSold	数值	销售月份；保留数值尺度；剩余未知按拟合数据中位数填补
81	CommunityMedian_OverallQual	数值	社区质量中位数；训练社区OverallQual中位数；未知社区回退总体
82	CommunityMedian_LotArea	数值	社区地块面积中位数；训练社区原始LotArea中位数；原始平方英尺
83	CommunityMedian_YearBuilt	数值	社区建造年份中位数；训练社区原始YearBuilt中位数；原始年份
84	RelativeQuality	数值	相对社区质量；原始OverallQual / 社区质量中位数
85	RelativeLotArea	数值	相对社区地块面积；原始LotArea / 社区地块面积中位数
86	CommunityYearDifference	数值	与社区建造年之差；原始YearBuilt - 社区建造年中位数

复现来源

交接代码：code/legacy/legacy_feature_engineering.py为F1-F5；code/legacy/feature_engineering.py为F6与填补；code/legacy/feature_selection.py为筛选；code/pipeline.py为最终C0及社区特征；code/reproduce.py重建完整矩阵并复现模型。原项目适配器快照、精确配置与权重信息保存在evidence/。

数据核对：最终train/test与0.11134版本字节SHA256一致；训练Id与原始标签保持不变；全部1460条训练行保留；86列含57数值、29类别。交接代码已实际重建特征并核对；验证记录在verification/。